Modelli DPM per problemi di clustering

Gaia Addis, Lucrezia Tusetti

Università degli Studi di Milano-Bicocca

19 Dicembre 2024

Indice

1 Introduzione al problema

2 Cenni al clustering Bayesiano non parametrico

3 Funzioni di perdita

4 Algoritmi: Greedy e SALSO

5 Studio di simulazione

6 Analisi di un dataset reale

Introduzione al problema

1

Modelli mistura, parametrici vs non parametrici:

- Stima dei parametri della mistura
- Assunzione sul numero delle componenti

Stima puntuale della partizione ottima:

- Probabilità a posteriori via MCMC
- Minimizzazione della perdita attesa

Cenni al clustering

2

Mistura di processo di Dirichlet

$$f(y|P) = \int K(y|\theta)\, dP(\theta)$$

$K(y|\theta)$ è una densità parametrica

P è una misura di probabilità e ha una distribuzione a priori q.c. discreta:

$$P = \sum_{j=1}^{\infty} w_j \delta_{\theta_j}$$

Cenni al clustering

2

Funzione di verosimiglianza dei dati condizionati alla partizione:

$$f(y_{1:N} \mid c) = \prod_{j=1}^{k_N} m(y_j) = \prod_{j=1}^{k_N} \int \prod_{n \in C_j} K(y_n \mid \theta) dP_0(\theta)$$

Distribuzione a posteriori, dove $p(c)$ è il Processo di Dirichlet:

$$p(c \mid y_{1:N}) \propto p(c) \prod_{j=1}^{k_N} m(y_j)$$

Binder's Loss

$$B(c, \hat{c}) = \sum_{i<j} aI(c_i = c_j)I(\hat{c}_i \neq \hat{c}_j) + bI(c_i \neq c_j)I(\hat{c}_i = \hat{c}_j)$$

a. errore di allocare due osservazioni in cluster differenti
b. errore di allocare due osservazioni nello stesso cluster

Binder: versione n-invarainte

Wade e Ghahramani

$$B_{\text{n-inv}}(\rho, \hat{\rho}) = \frac{2}{n^2} B(\rho, \hat{\rho}) = \sum_{S \in \rho} \left(\frac{|S|}{n} \right)^2 + \sum_{\hat{S} \in \hat{\rho}} \left(\frac{|\hat{S}|}{n} \right)^2 - 2 \sum_{S \in \rho} \sum_{\hat{S} \in \hat{\rho}} \left(\frac{|S \cap \hat{S}|}{n} \right)^2$$

In questo caso la partizione ottima minimizza, considerando $a = b = 1$

$$\sum_{i<j} \left(I(c_i = c_j) - p_{ij} \right)^2 \qquad B_{\text{n-inv}}(\rho, \hat{\rho}) \leq 1 - \frac{1}{N}$$

Problema: sovrastima del numero dei cluster

Binder: versione generalizzata

Dahl et al.

$$B_{\text{general}}(\rho, \hat{\rho}) = a \sum_{S \in \rho} \left(\frac{|S|}{n} \right)^2 + b \sum_{\hat{S} \in \hat{\rho}} \left(\frac{|\hat{S}|}{n} \right)^2 - (a+b) \sum_{S \in \rho} \sum_{\hat{S} \in \hat{\rho}} \left(\frac{|S \cap \hat{S}|}{n} \right)^2$$

dove $a > b$

per risolvere il problema di sovrastima del numero di cluster

Variation of information

Wade e Ghahramani

$$VI(\rho, \hat{\rho}) = H(\rho) + H(\hat{\rho}) - 2I(\rho, \hat{\rho})$$

$$= -H(\rho) - H(\hat{\rho}) + 2H(\rho, \hat{\rho})$$

$$= \sum_{S \in \rho} \frac{|S|}{n} \log_2 \left(\frac{|S|}{n} \right) + \sum_{\hat{S} \in \hat{\rho}} \frac{|\hat{S}|}{n} \log_2 \left(\frac{|\hat{S}|}{n} \right) - 2 \sum_{S \in \rho} \sum_{\hat{S} \in \hat{\rho}} \frac{|S \cap \hat{S}|}{n} \log_2 \left(\frac{|S \cap \hat{S}|}{n} \right)$$

e si ottiene che

$$\hat{c}^* = \arg\min_{\hat{c}} \sum_{i=1}^{n} \log_2 \left(\sum_{j=1}^{n} I(\hat{c}_j = \hat{c}_j) \right) - 2 \sum_{i=1}^{n} \mathbb{E} \left[\log_2 \left(\sum_{j=1}^{n} I(c_j = c_i) I(\hat{c}_j = \hat{c}_i) \right) \mid y_{1:N} \right]$$

$$VI(\rho, \hat{\rho}) \leq log_2(N)$$

VI: versione generalizzata

Dahl et al.

$$VI_{general}(\rho, \hat{\rho}) = bH(\rho) + aH(\hat{\rho}) - (a+b)I(\rho, \hat{\rho})$$

$$= -aH(\rho) - bH(\hat{\rho}) + (a+b)H(\rho, \hat{\rho})$$

$$= a \sum_{S \in \rho} \frac{|S|}{n} \log_2 \left(\frac{|S|}{n} \right) + b \sum_{\hat{S} \in \hat{\rho}} \frac{|\hat{S}|}{n} \log_2 \left(\frac{|\hat{S}|}{n} \right) - (a+b) \sum_{S \in \rho} \sum_{\hat{S} \in \hat{\rho}} \frac{|S \cap \hat{S}|}{n} \log_2 \left(\frac{|S \cap \hat{S}|}{n} \right)$$

dove $a < b$ per risolvere il problema di sottostima del numero dei cluster.

Greedy Search Algorithm
Wade e Ghahramani, 2018

- **START**: $\hat{c}$ (partizione iniziale) selezionata da MCMC / hierarchical
- Passi localmente ottimali in un intorno di partizioni (step-size: l) definite rispetto alla funzione di perdita e al diagramma di Hasse
- Calcolo perdita attesa a posteriori $\mathbb{E}(L|x)$ $\forall$ partizione
- **STOP**: non si ottengono più riduzioni significative della perdita attesa a posteriori / max numero iterazioni

Greedy Search Algorithm
Wade e Ghahramani, 2018

- **Funzioni di perdita utilizzabili**: Binder's loss e limite inferiore VI (no generalizzate), perchè richiede in input matrice di similarità a posteriori

- **ATTENZIONE** a minimi locali ($\hat{c}$, l) <–> trappola Hasse
  -> inizializzazioni multiple / l grande

- **Complessità computazionale**: $O(lN^2)$

SALSO
Dahl, Johnson e Muller, 2021

Sequentially-Allocated Latent Structure Optimization

1. **INIZIALIZZAZIONE**: partizione può essere inizializzata in due modi con V.A.unif. p_{SA}
   - **Assegnazione sequenziale**: u.s. assegnate una alla volta ad un cluster esistente/nuovo, min $\mathbb{E}(L|x)$. Ordine u.s. allocazione = permutazione casuale indici.
   - **Assegnazione casuale**: partizione casuale tramite labels cluster 1,..., k_d

2. **SWEETENING**: riallocazione iterativa delle u.s. una alla volta e casualmente (simil sequenziale ma NON one-shot) per minimizzare. $\mathbb{E}(L|x)$ stop -> n inv

3. **ZEALOUS UPDATE**: distruzione e ricostruzione casuale dei cluster per sfuggire ai minimi locali [opzionale -> $n_{maxZealous}$], min $\mathbb{E}(L|x)$ -> keep or drop

4. **RECORDING**: registrazione $\mathbb{E}(L|x)$ per la partizione corrente

SALSO
Dahl, Johnson e Muller, 2021

- **Greedy Stocastico**: scelte casuali in ogni fase
- **Funzioni di perdita utilizzabili**: svariate, tra cui le nostre versione generalizzate
- **ATTENZIONE** a minimi locali -> più esecuzioni **MA**

1. "imbarazzamente parallelo"
2. shortcut per calcolo $\mathbb{E}(L|x)$
3. numero max cluster desiderati k_d

- **Complessità computazionale**: $O(Hk_dk_hN)$

Dataset simulato: mistura di 4 normali univariate

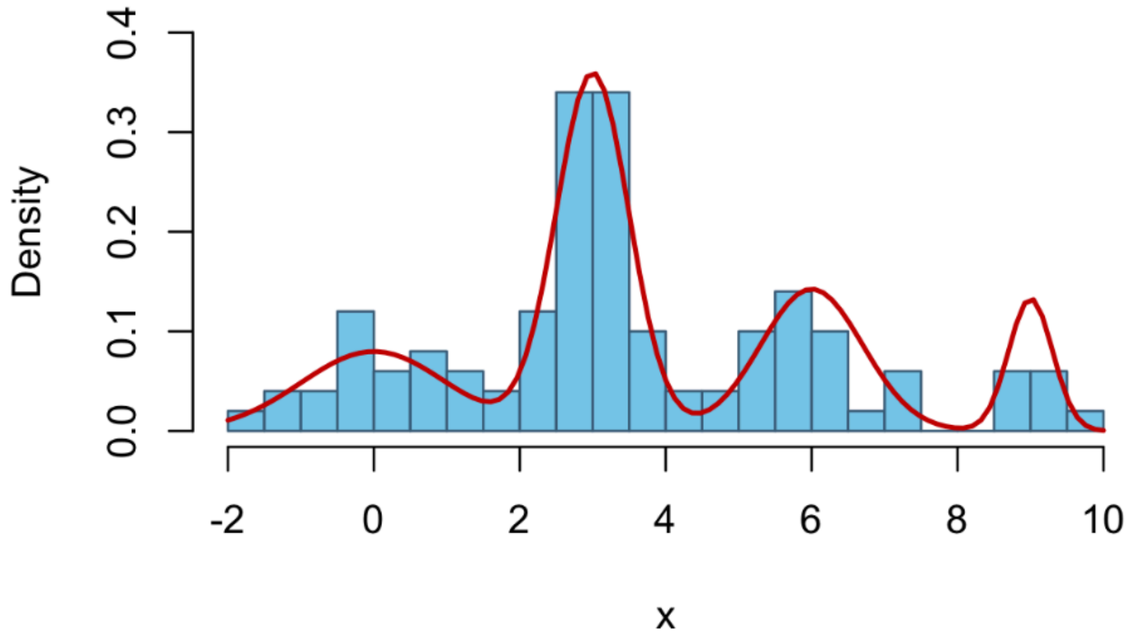

Figura 1: Istogramma dei dati generati dalla mistura con funzione di densità sovrapposta

$$n = 100$$

$$X_i \overset{iid}{\sim} \sum_{j=1}^{4} p_j N(\mu_j, \sigma_j)$$

$$p = (0.2, 0.45, 0.25, 0.1)$$

$$\mu = (0, 3, 6, 9)$$

$$\sigma = (1, 0.5, 0.7, 0.3)$$

Studio di simulazione

DPM "location" con kernel Gaussiano univariato

$$\tilde{f}(x) = \int_{\mathbb{R}^+} \int_{\mathbb{R}} K(x; \theta, \sigma^2)\, d\tilde{P}(\theta)\, dIG(\sigma^2)$$

Modello in forma gerarchica

$$X_i|\theta_i \overset{ind}{\sim} K(.; \theta_i, \sigma^2) \qquad \sigma^2 \sim Inv - Gamma(1,1)$$

$$\theta_i|\tilde{P} \overset{iid}{\sim} \tilde{P}, \quad i = 1, \ldots, n \qquad \tilde{P} \sim DP(\alpha, P_0)$$

Stima f via MC + Gibbs Sampling

$$\hat{f}(x) \approx \frac{1}{M} \sum_{m=1}^{M} \mathbb{E}[\tilde{f}(x)|\underline{X}, \underline{\theta}^{(m)}, \sigma^{2(m)}]$$

Studio di simulazione

5

f stimata e cluster reali

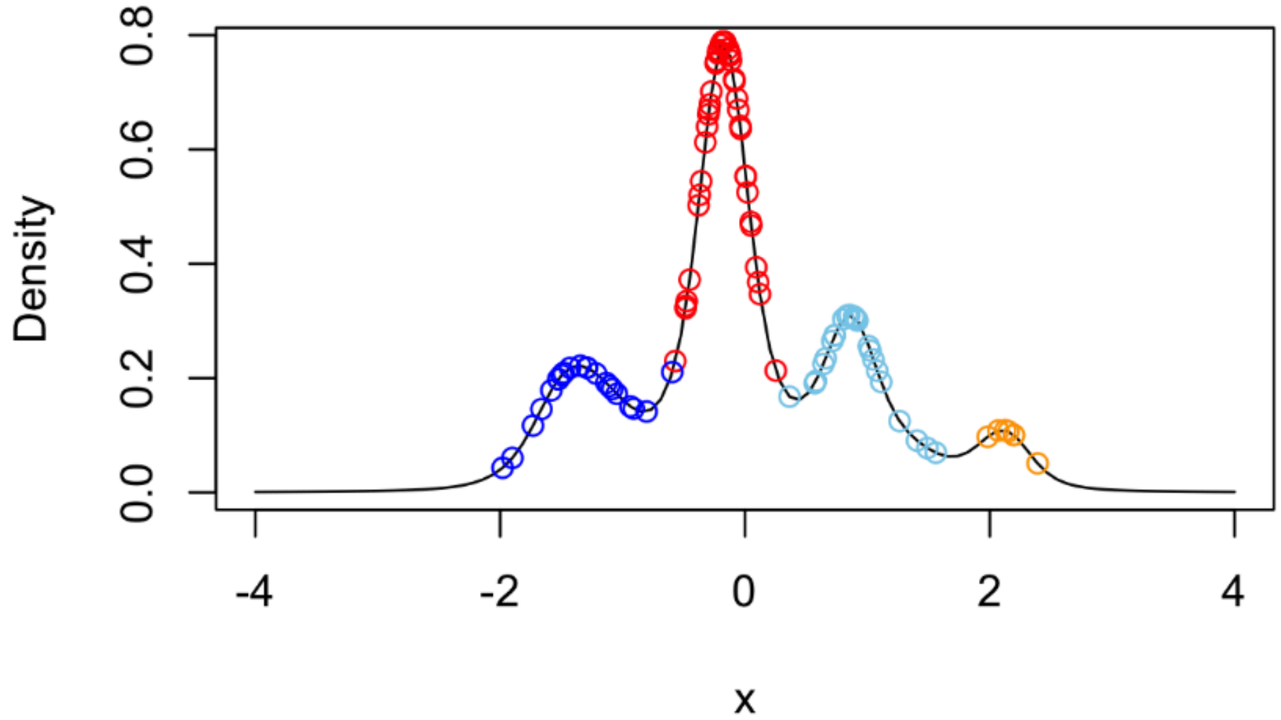

OBIETTIVO: confrontare le funzioni di perdita e le prestazioni di Greedy e SALSO in termini di accuratezza, numero di cluster stimati e tempo di esecuzione.

Risultati GREEDY

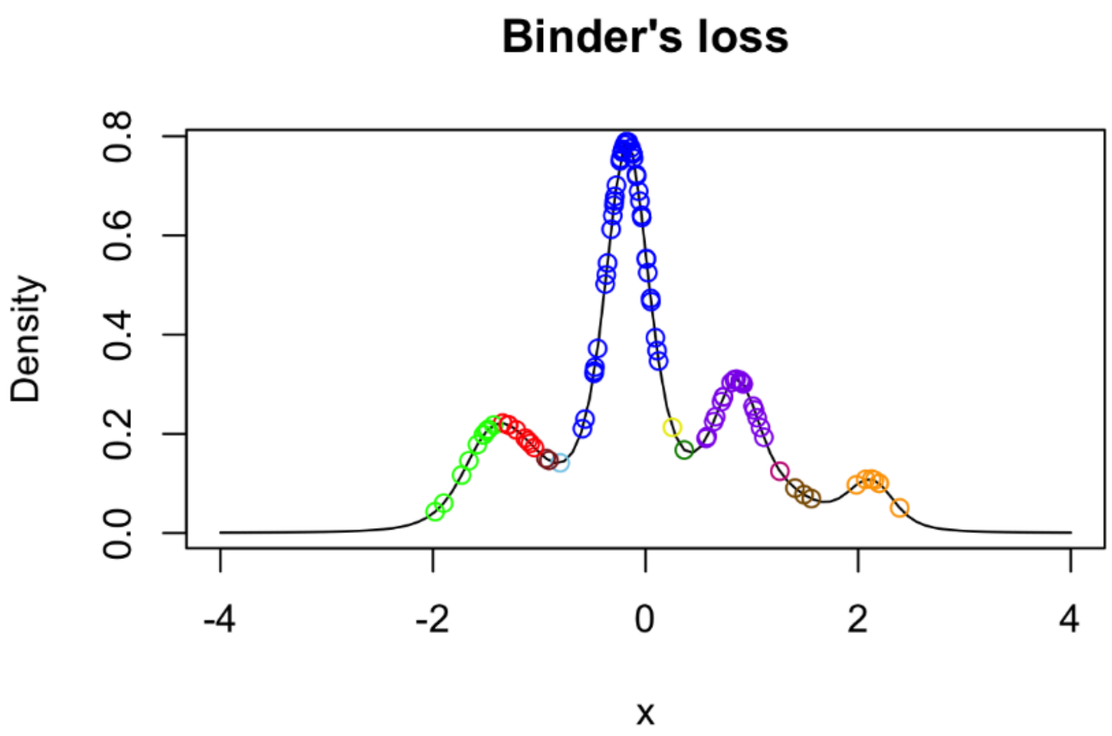

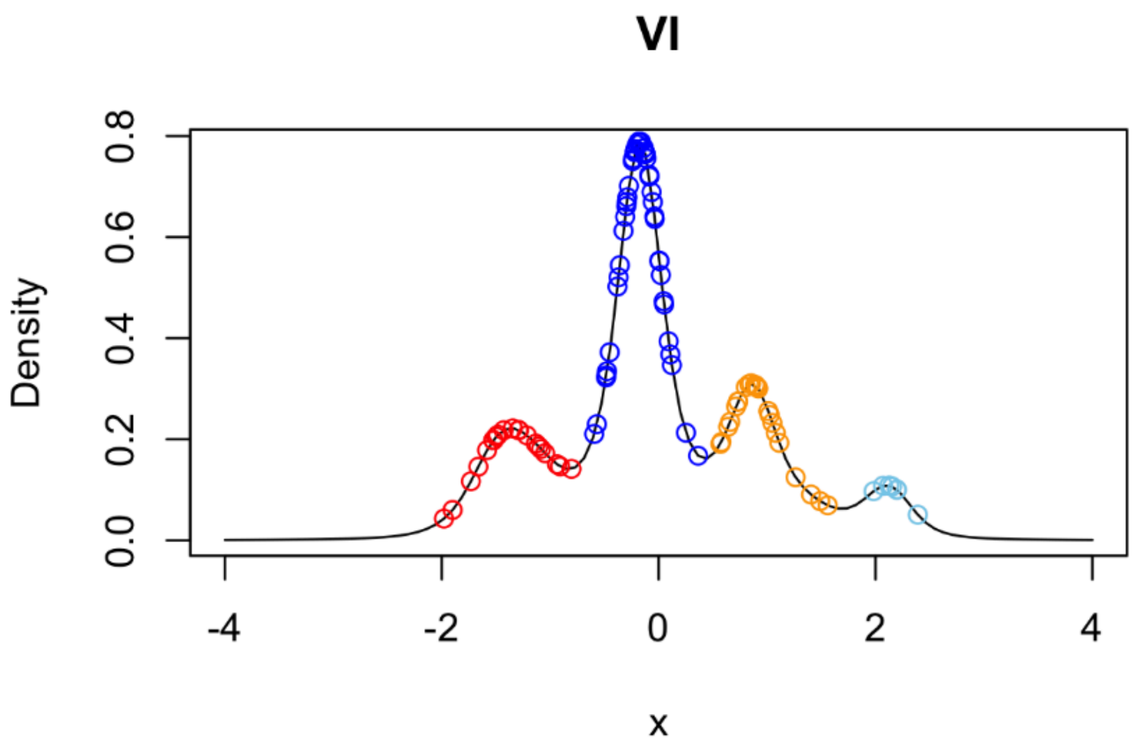

Loss	k_N^*	N_i	$\mathbb{E}(L\|x)$	$time_{sec}$
Binder	12	18	0.162	17.823
VI	4	2	0.173	32.962

Studio di simulazione

5

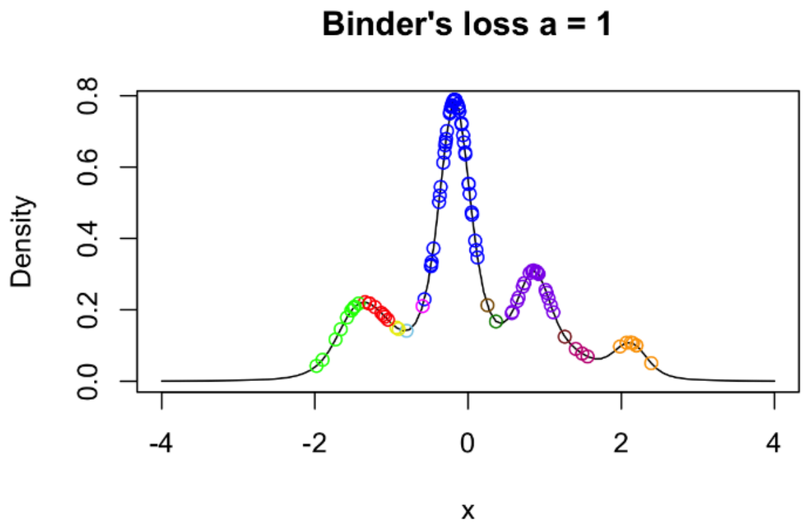

Risultati SALSO

Loss	k_N^*	N_i	$\mathbb{E}(L\|x)$	$time_{sec}$
Binder $a = 1$	12	17	0.163	0.071
Binder $a = 1.6$	4	2	0.115	0.026
VI $a = 1$	5	5	1.444	0.029
VI $a = 1.1$	4	2	1.365	0.025

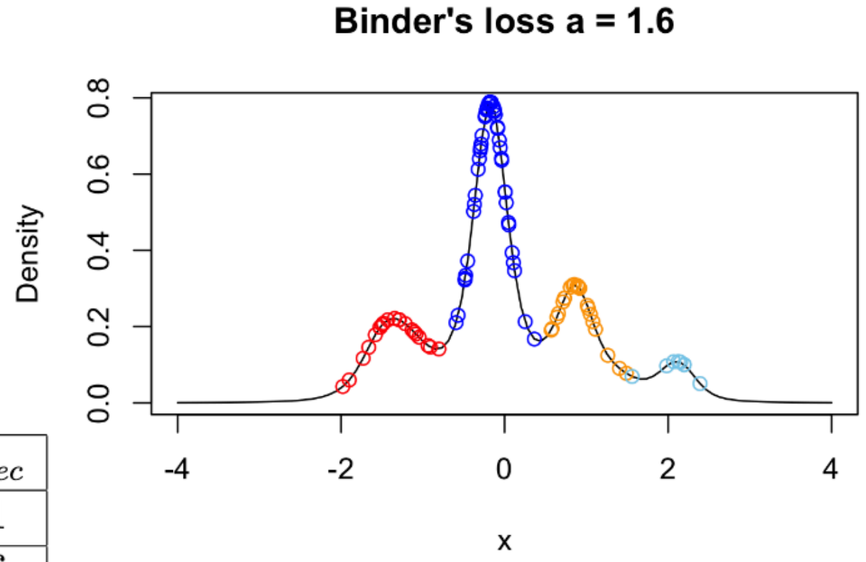

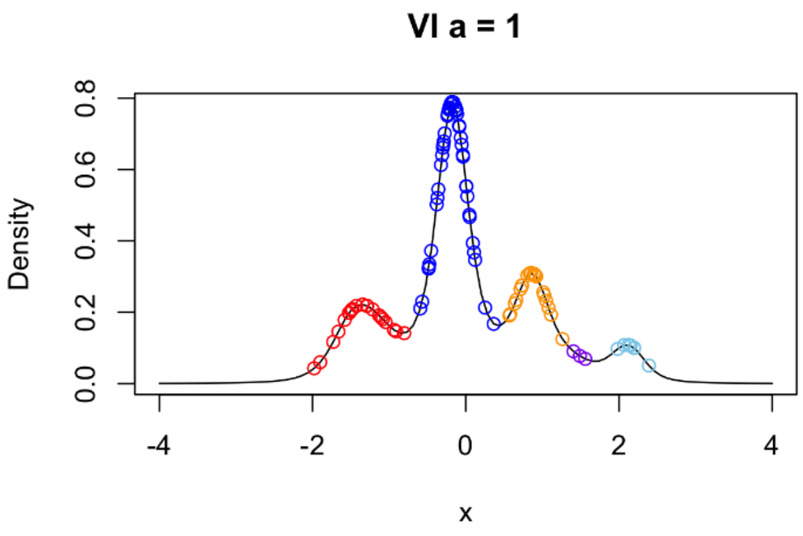

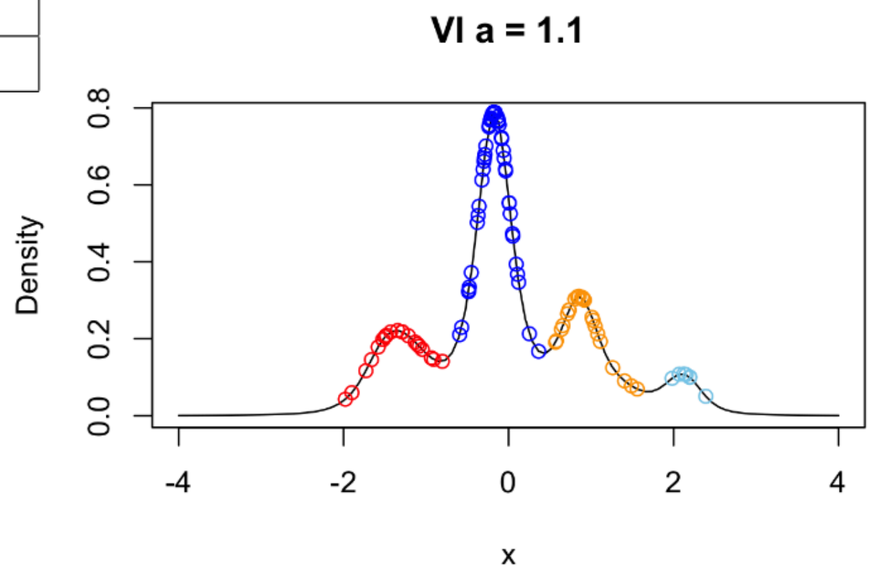

Analisi di un dataset reale

Country Data

- Obiettivo dell'analisi
- Gdpp, Exports, Imports, Total Fertility, Life Expentancy

Applicazione

- Binder's Loss generalizzata - SALSO
- Creazione di 4 cluster interpretabili

Risultati ottenuti

Misture e assegnazioni delle istanze ai cluster

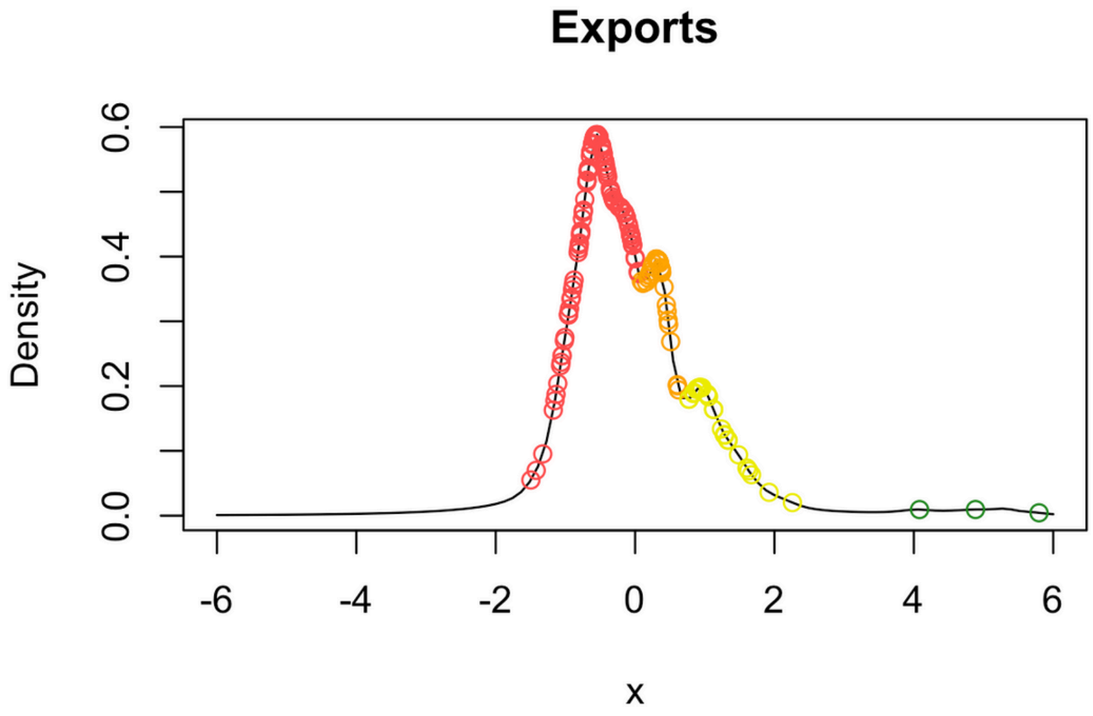

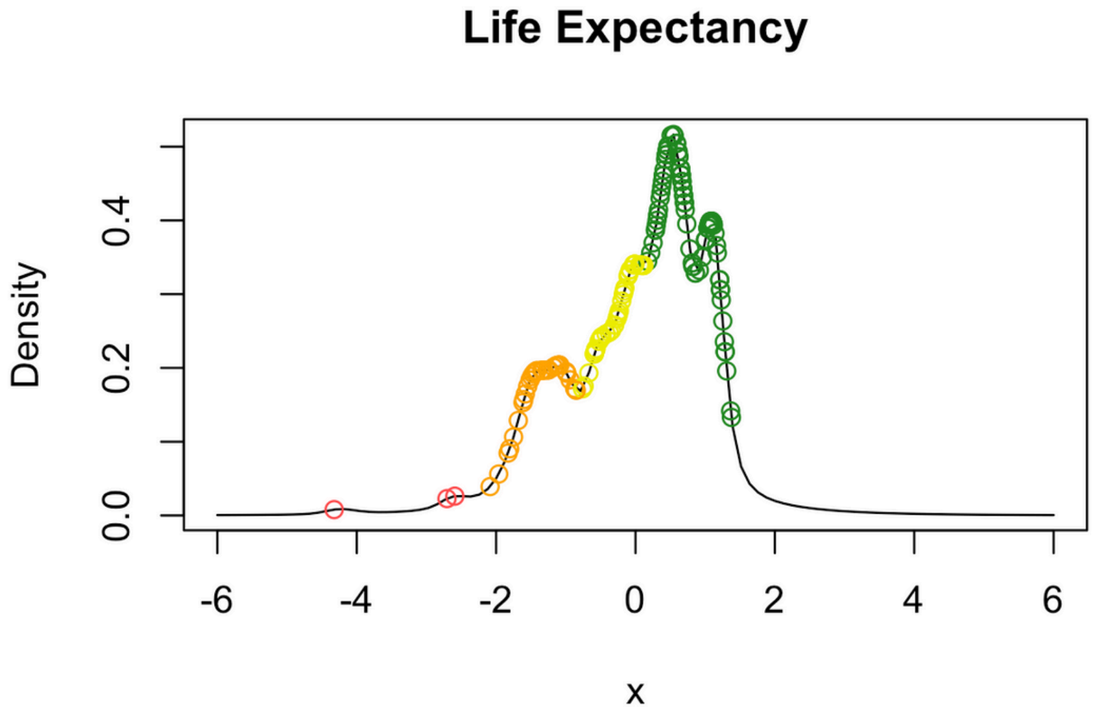

GDPP

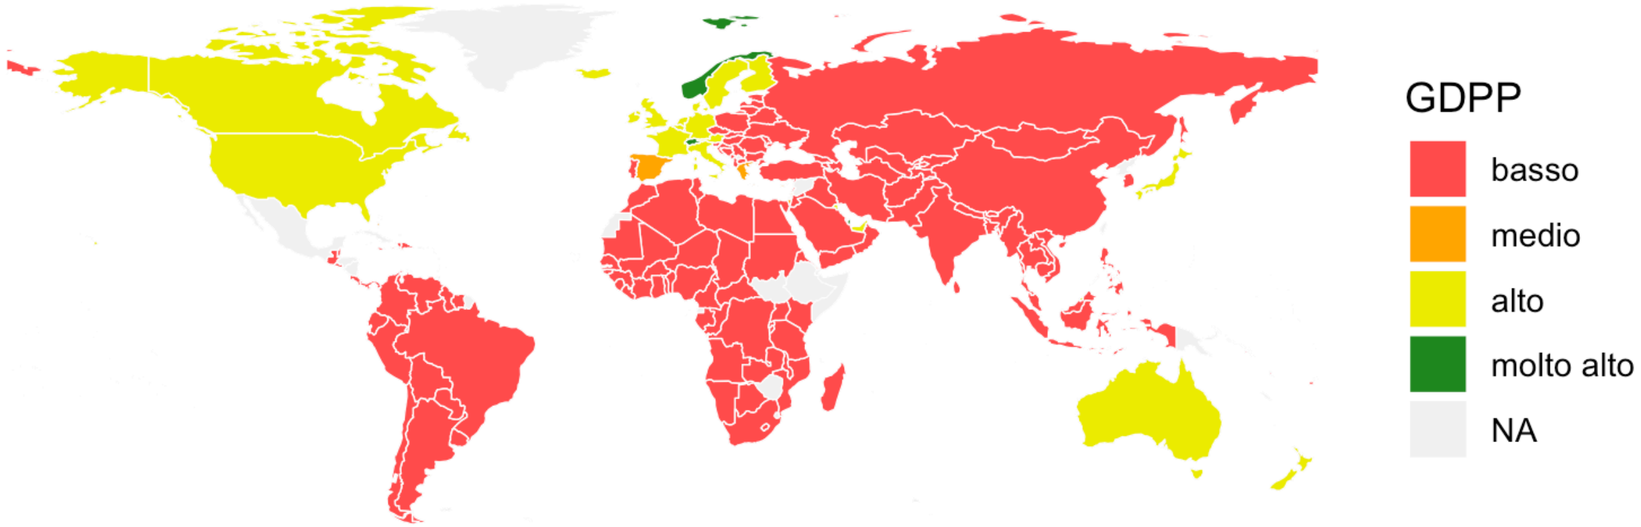

Divario molto marcato tra i Paesi del Nord e Sud del mondo.
Il Gdpp anticipa i risultati che si ottengono dalle variabili medico-sanitarie.

Exports ed Imports

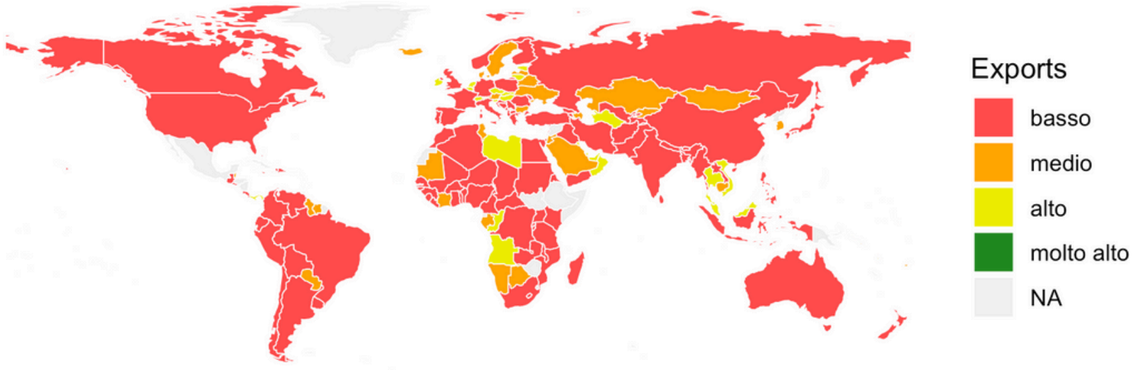

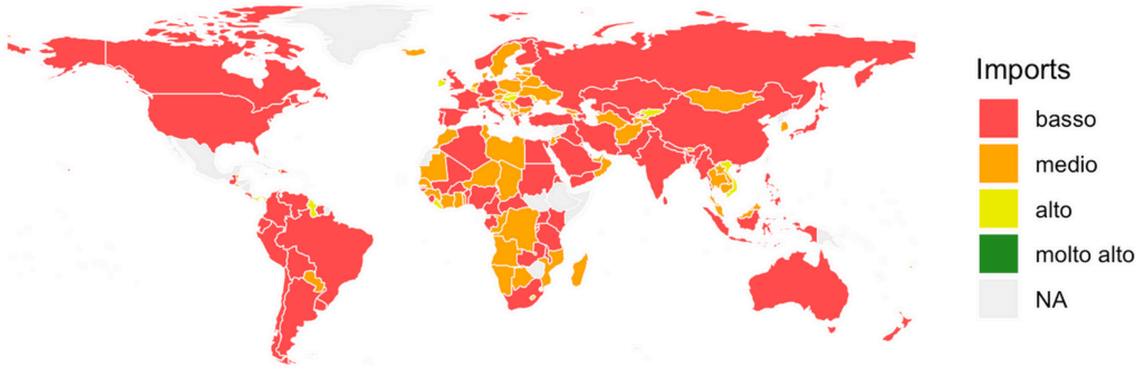

Solo pochi Paesi registrano livelli di Exports elevati.
Esportazioni: petrolio, servizi finanziari o tecnologici, beni manifatturieri.

I Paesi sviluppati producono in settori ad alto valore aggiunto e la necessità di importazioni fisiche è ridotta.

Life Expectancy e Total Fertility

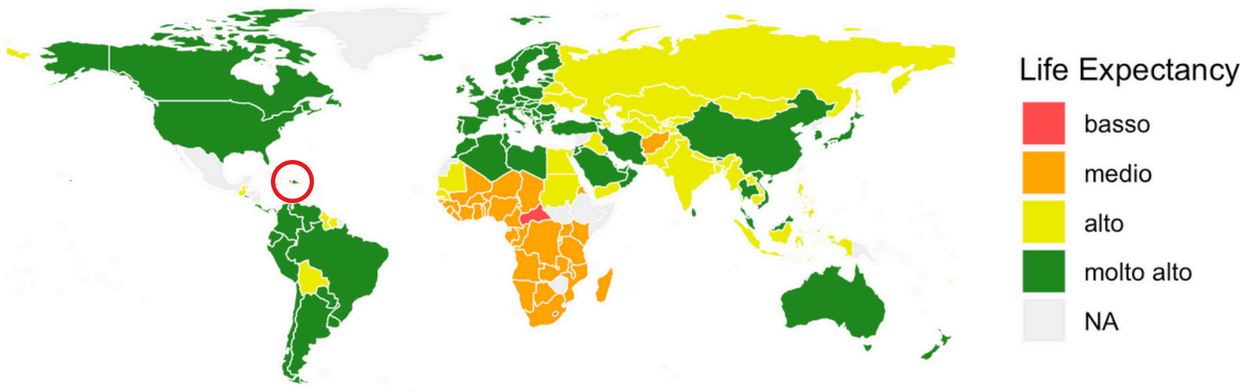

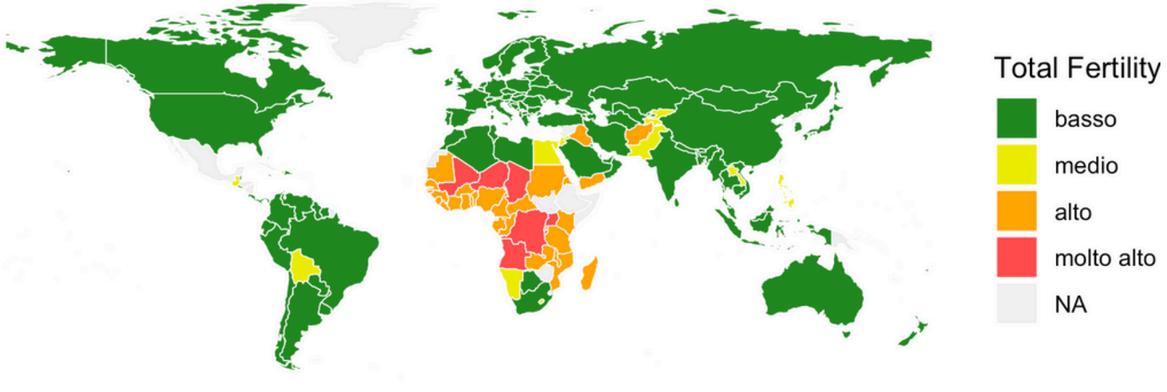

L'aspettativa di vita è strettamente legata alla situazione medico-sanitaria dei Paesi.

Il numero di figli medio per donna è legato alla cultura tradizionale, accesso alla contraccezione, dipendenza economica dai figli.